Universidad del Valle de Guatemala

Facultad de Ingeniería
Departamento de Ciencias de la Computación
CC3084 – Data Science
Semestre II – 2026

Laboratorio 1
Series de Tiempo

Cuánta gente entra a Guatemala, mes a mes, y qué modelo la predice mejor

Grupo 6

26 de julio de 2026

De qué va este informe

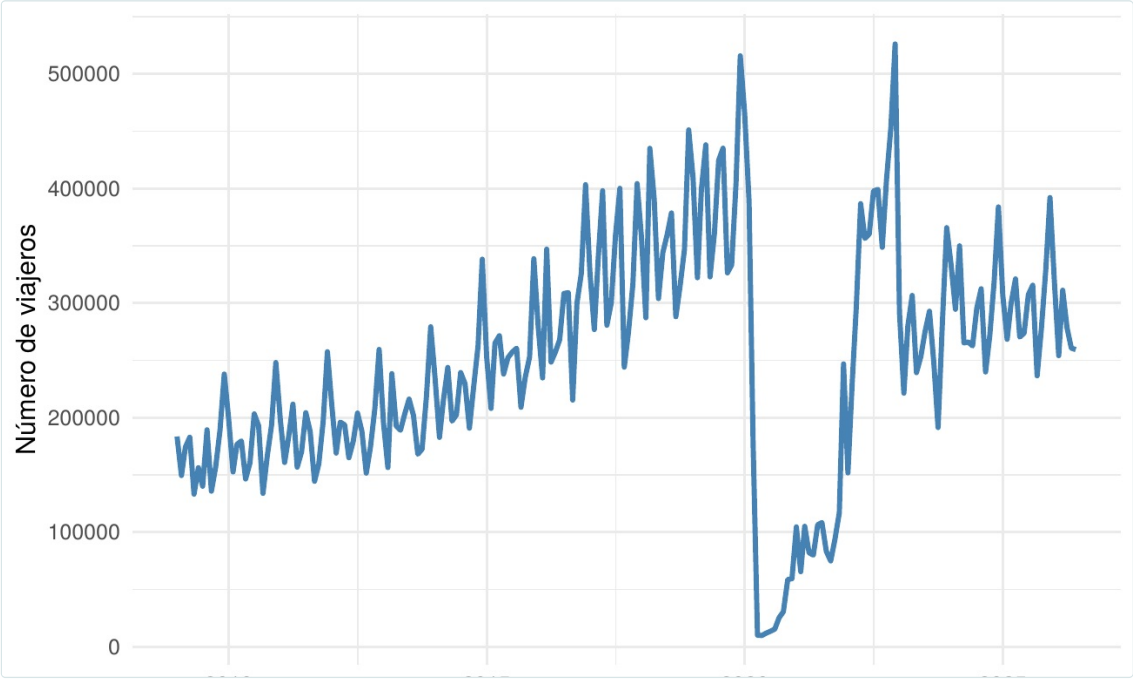
Trabajamos con el histórico mensual de ingreso de viajeros internacionales a Guatemala (2009-2026, 161,036 registros): año, mes, vía de ingreso, frontera, país de residencia, región, tipo de viajero y cantidad de viajeros. La idea es entender cómo se mueve esa cifra en el tiempo y ver qué tan bien la podemos predecir con distintos modelos (ARIMA, ETS, Holt-Winters, Seasonal Naive y Prophet).

Un detalle importante de los datos: entre 2022 y 2023 la categoría “tipo de viajero” dejó de contar a los viajeros no turísticos de alta frecuencia (comercio fronterizo, tránsito), así que la categoría “Viajero” se desploma en 2023 sin que eso sea una caída real del turismo. Por eso, cuando comparamos estructura a lo largo de todo el periodo, nos apoyamos en el total de viajeros y en los cortes por país/vía, que sí son consistentes.

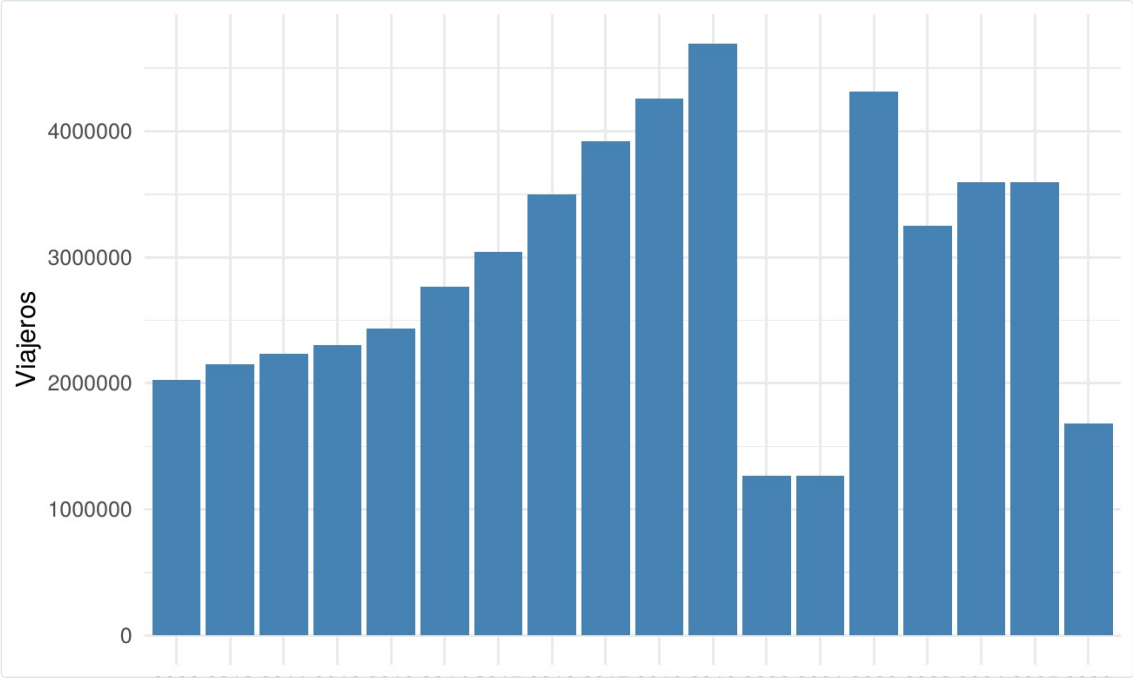
Aclaración de siempre: estos datos son solo para uso académico, no son datos oficiales del INGUAT ni del Instituto Guatemalteco de Migración.

1. Primero, un vistazo a los datos (EDA)

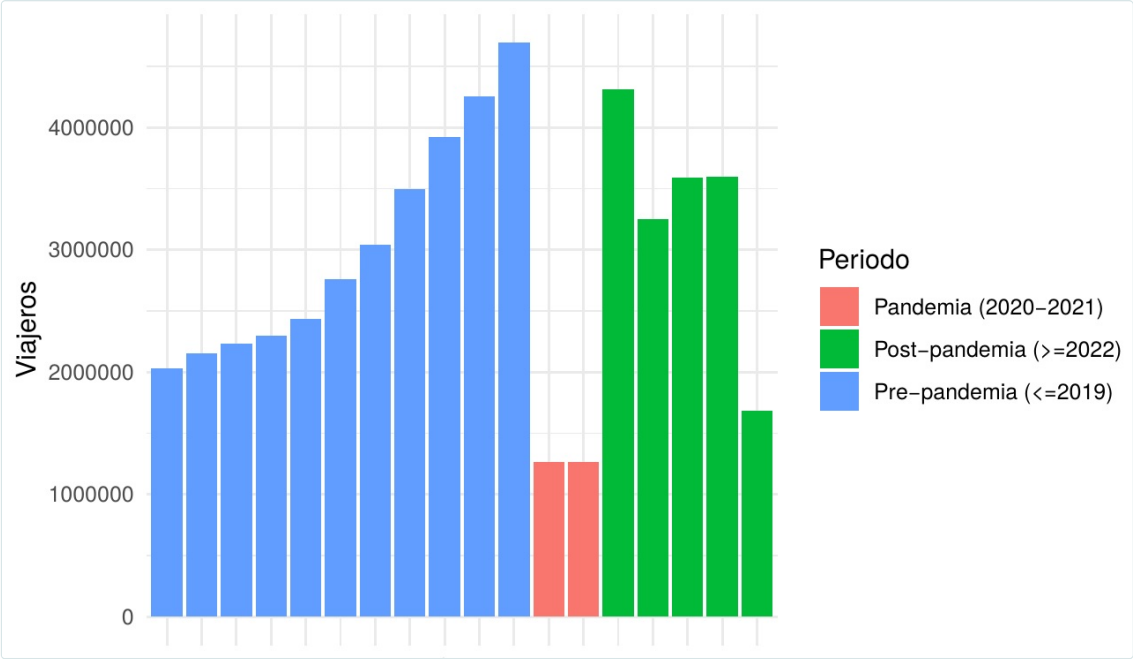
¿Cómo se mueve el total de viajeros en el tiempo?



Se ve clarísimo: tendencia para arriba entre 2009 y 2019, con su patrón estacional de todos los años (picos en temporada alta). Después el golpe de 2020 – brutal – y desde 2022 una recuperación fuerte que incluso llega a superar el pico prepandemia por momentos, para después acomodarse un poco por debajo del máximo histórico de 2019.

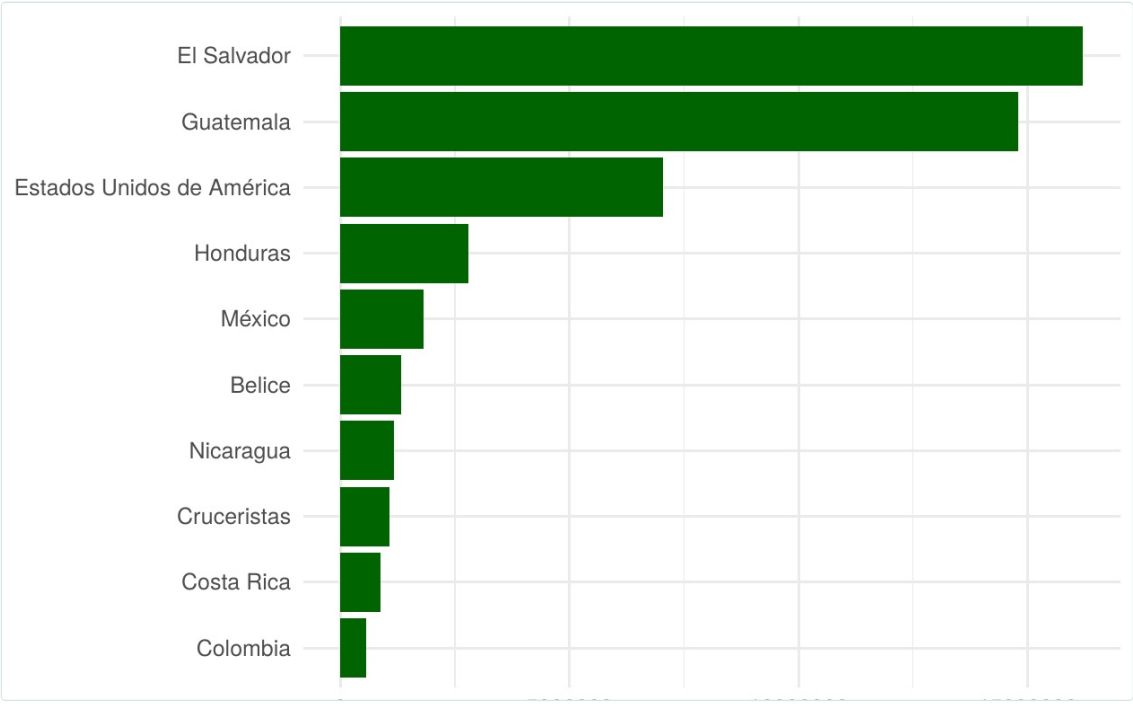


Antes, durante y después de la pandemia

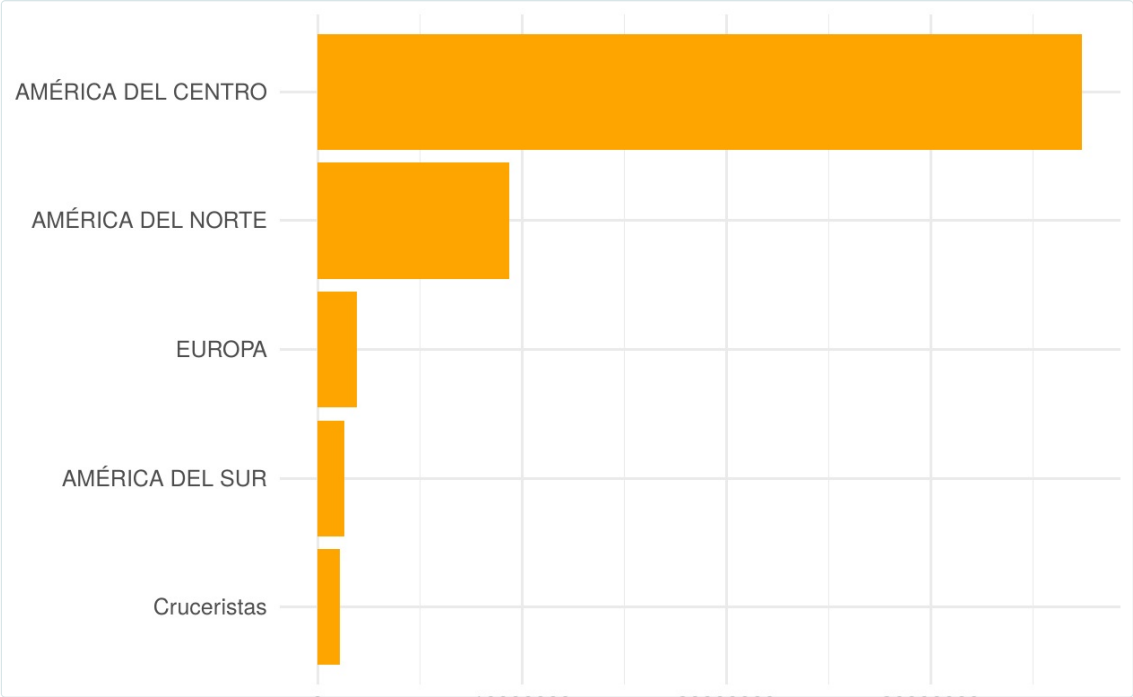


Entre 2019 y 2020 el número de viajeros se cayó cerca de un **73%**. La caída es abrupta en 2020 y la recuperación es gradual en 2021. Desde 2022 el crecimiento es fuerte, aunque sin llegar todavía al techo de 2019. En 2023-2025 la cosa se estabiliza bien por encima de los niveles pandémicos, aunque un poquito por debajo del máximo histórico.

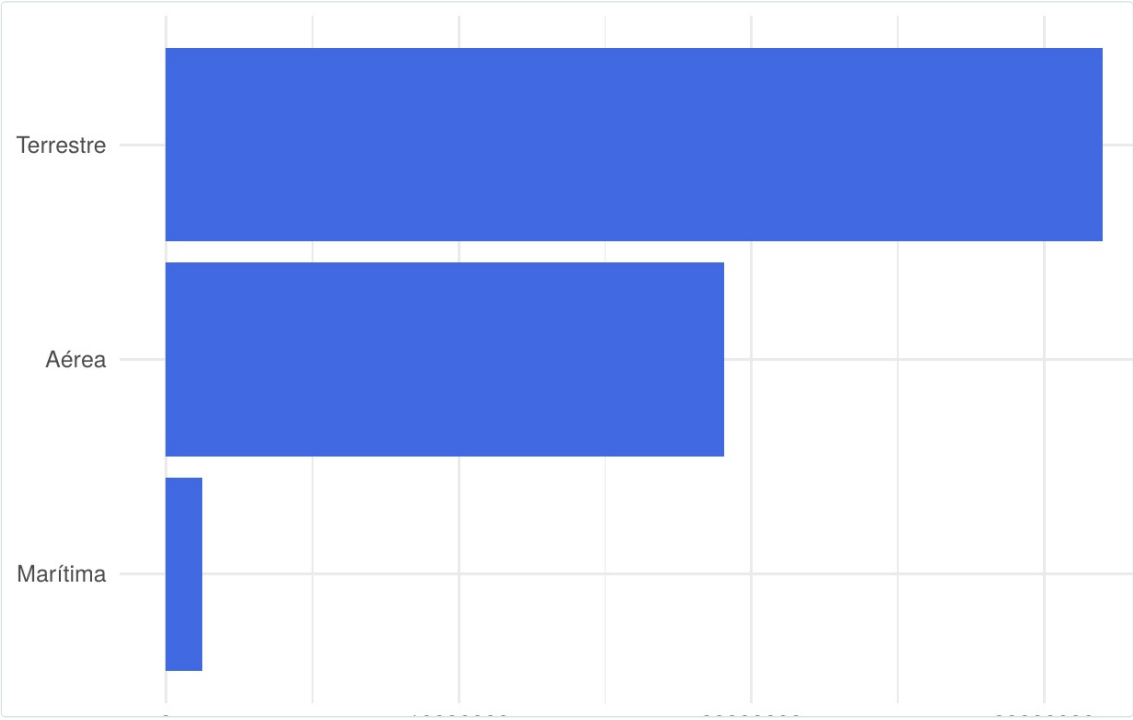
¿De dónde viene la gente y por dónde entra?



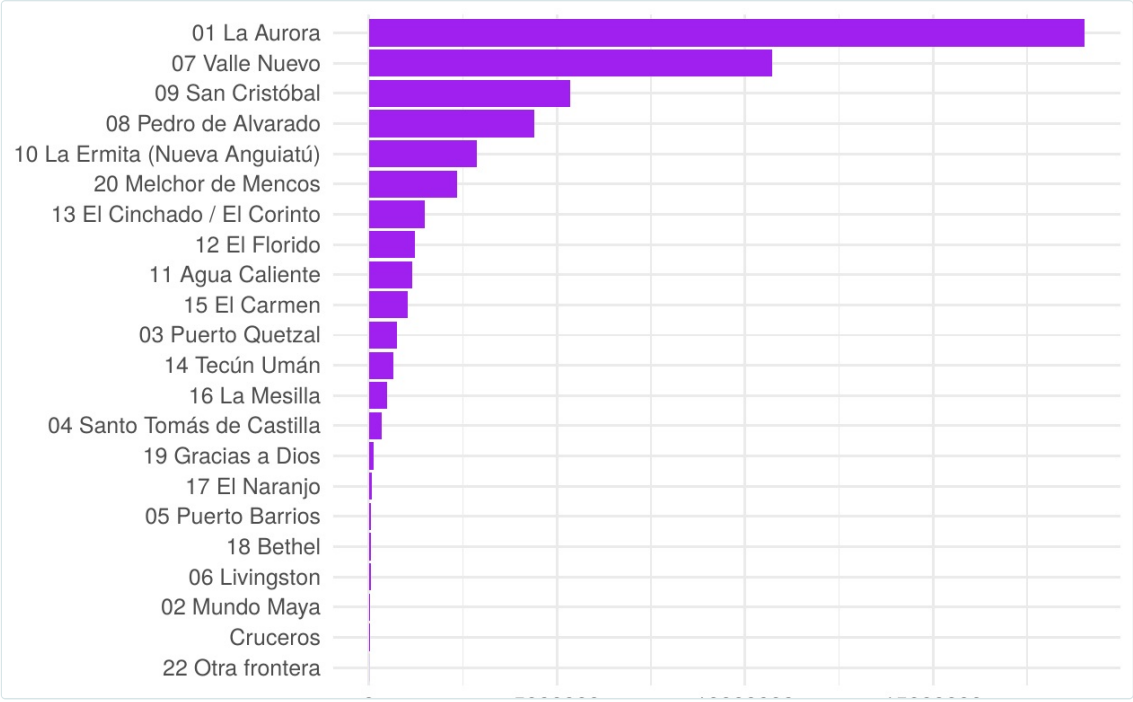
Los tres países que más aportan son **El Salvador**, **Guatemala** (registros fronterizos/intrarregionales bajo esta agrupación) y **Estados Unidos**. Se llevan la mayoría de los registros, muy por encima de Honduras, México, Belice, Nicaragua, Cruceristas, Costa Rica y Colombia.



Por región, **América del Centro** manda por mucho, seguida de **América del Norte**. Europa, América del Sur y Cruceristas quedan bien atrás. O sea que el movimiento de viajeros hacia Guatemala es sobre todo centroamericano.



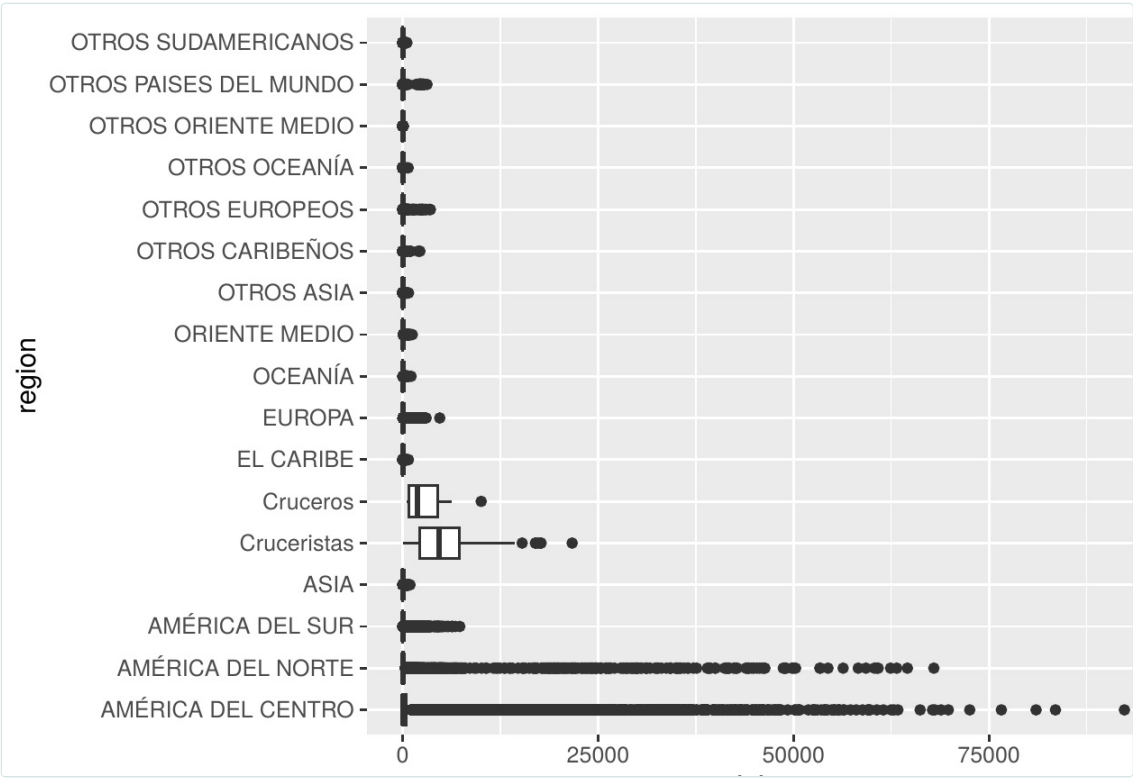
La vía **Terrestre** es la más usada, después la **Aérea**, y la **Marítima** es casi anecdótica en volumen.



Las fronteras con más movimiento acumulado son **La Aurora** (el aeropuerto), **Valle Nuevo** y **San Cristóbal**, seguidas de **Pedro de Alvarado** y **La Ermita (Nueva Anguiatú)**. Cuadra con lo anterior: mucha entrada terrestre desde El Salvador y La Aurora como puerta aérea principal.

Faltantes, duplicados y datos atípicos

Buenas noticias: **cero valores faltantes** y **cero duplicados** en todo el dataset.



El boxplot de *viajero* por región muestra un montón de puntos “atípicos” por encima de valores bajísimos, sobre todo en América del Centro y del Norte. Pero ojo, esto no es un error de captura: la variable es naturalmente muy asimétrica (hay registros agregados de cruces masivos junto a registros chiquitos), así que hay que mirarlo con la estadística descriptiva antes de sacar conclusiones apresuradas.

Estadística descriptiva

La variable *viajero* va de 0 a 92,336 por registro, con una mediana de apenas 7 y una media de 324.70 – la diferencia enorme entre media y mediana ya avisa del sesgo. La fecha cubre de enero 2009 a junio 2026.



El histograma lo confirma: la inmensa mayoría de registros son valores chicos y unos pocos (cruces fronterizos de alto tráfico) se disparan. No es un error, es la naturaleza agregada del dato.

Tipo de viajero	Promedio	Mediana	Desv. estándar	Total acumulado
Cruceristas	5,414	4,455	4,226	1,104,402
Excursionista	460	10	1,834	9,069,184
Turista	319	6	2,611	37,642,729
Viajero	193	8.18	1,281	4,471,622

Lo que nos llevamos de esta parte: el sesgo tan fuerte de *viajero* hay que tenerlo en la mira para todo lo que sigue (por eso evaluamos Box-Cox en cada serie), y la demanda está concentrada en pocos países, pocas regiones y pocas fronteras – lo cual, de hecho, facilita bastante la vida a la hora de priorizar dónde poner atención.

2. Train / test

Dividimos cada serie de forma cronológica (nada de aleatorio, porque es serie de tiempo): 70% entrenamiento y 30% prueba, tomando primero el 70% de los meses más antiguos y dejando el resto para validar. Esto se hizo serie por serie, así que la fecha de corte varía un poco entre ellas según cuántos datos tiene cada una.

3. Las series que construimos

Con el set de entrenamiento armamos series mensuales agregando el número de viajeros. La obligatoria (**total general**) más dos categorías, como pedía el enunciado:

- **Top 3 países** (por total acumulado): El Salvador, Guatemala, Estados Unidos.
- **Vías de ingreso**: Aérea, Terrestre, Marítima.

En total, **7 series**: General, El Salvador, Guatemala, Estados Unidos, Vía Aérea, Vía Terrestre y Vía Marítima.

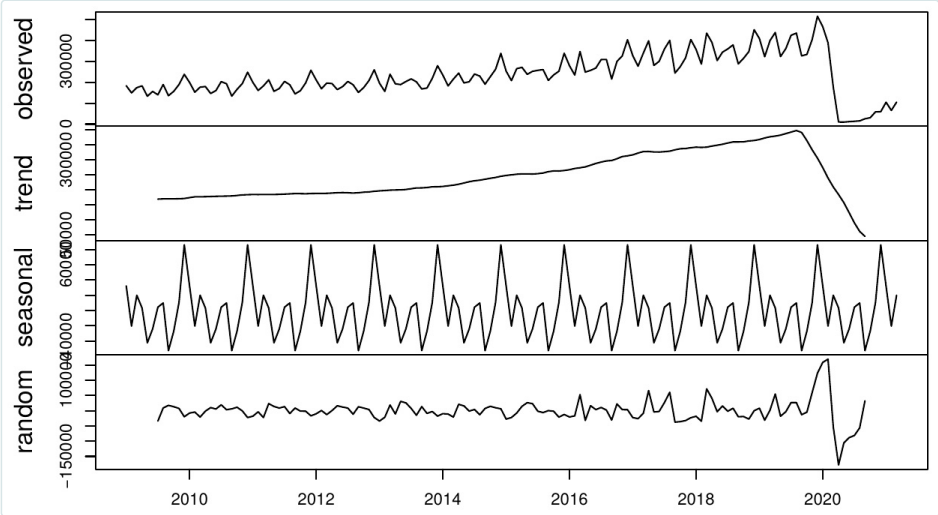
4. Cada serie, en corto

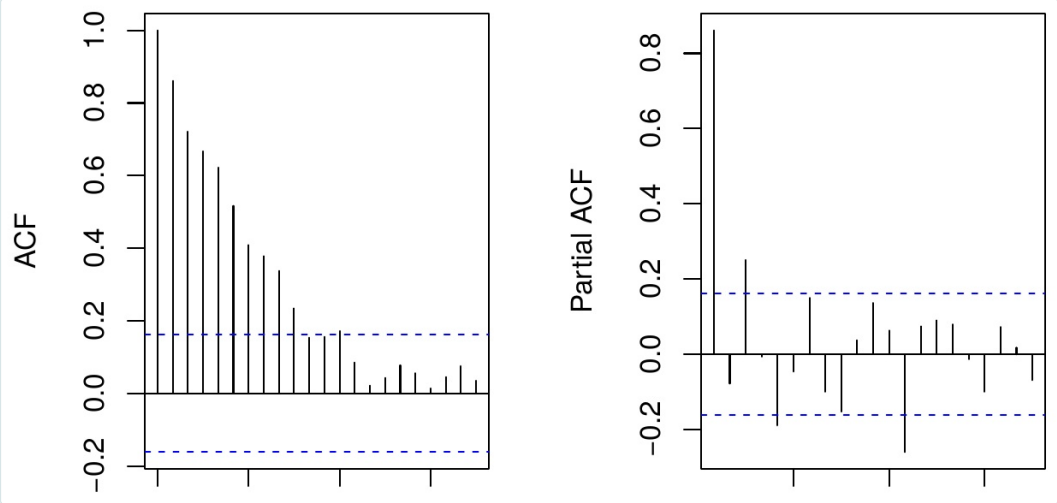
A cada una le aplicamos el mismo procedimiento: revisarla a ojo, descomponerla, ver si hace falta transformar (Box-Cox) y diferenciar (ACF + Dickey-Fuller), probar varios ARIMA y quedarnos con el mejor por AIC/BIC y residuos, y compararlo contra ETS, Holt-Winters, Seasonal Naive y Prophet sobre el conjunto de prueba (MAE y RMSE). Aquí va el resumen de cada una — el análisis a fondo, con todos los porqués, está en la sección de resultados comparativos más adelante.

General (total de viajeros)

Periodo de entrenamiento: ene-2009 a mar-2021 · mensual.

Tendencia clara para arriba de 2009 a 2019, con su estacionalidad de cajón cada año. Luego el batacazo de 2020 por la pandemia, y una recuperación que arranca en 2021.





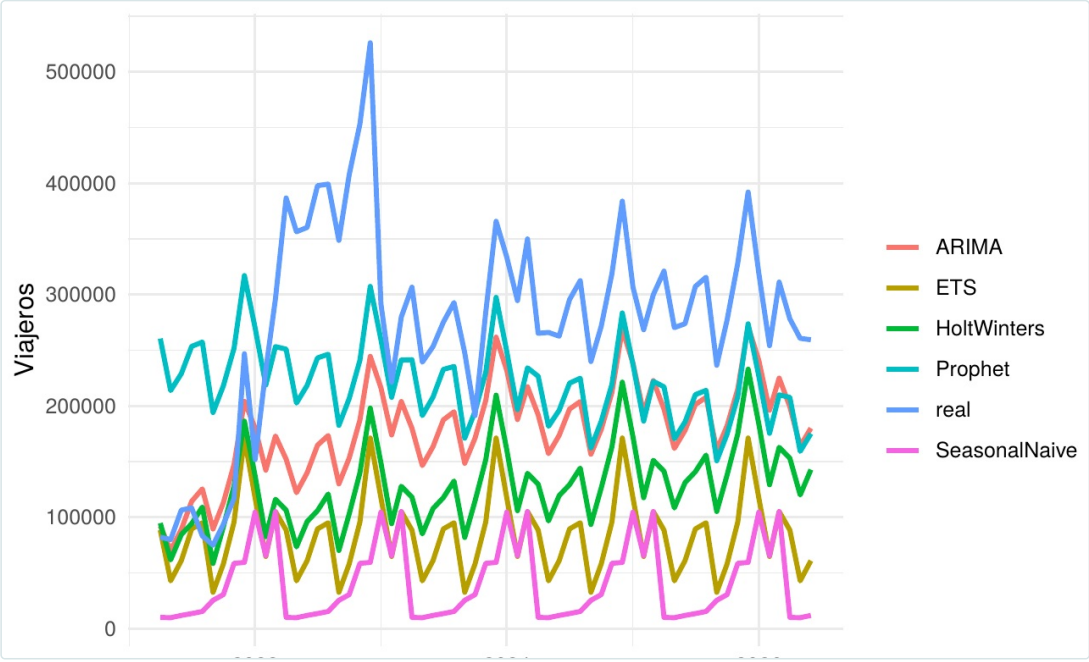
Box-Cox sugerido λ=0.675 (¿se transformó? Sí). ADF p=0.393, d=1, D=0. ADF no rechaza raíz unitaria (p=0.393) → no estacionaria en media, se corrige con una diferencia regular (d=1). Con Box-Cox (λ=0.675) se estabiliza bastante la varianza.

Candidatos ARIMA probados (ganador en negrita más abajo):

Candidato	AIC	BIC
ar_mayor	2373.99	2391.89
auto	2377.06	2386.01
simple	2408.64	2420.57
ma_mayor	2412.28	2427.19

Nos quedamos con **ARIMA(2,1,1)(1,0,1)[12]** (AIC 2373.99, BIC 2391.89). Ljung-Box p=0.912 → residuos limpios, buen ajuste.

El ETS automático fue ETS(A,N,A) (AIC 3867.54); también se corrieron Holt-Winters, Seasonal Naive y Prophet.



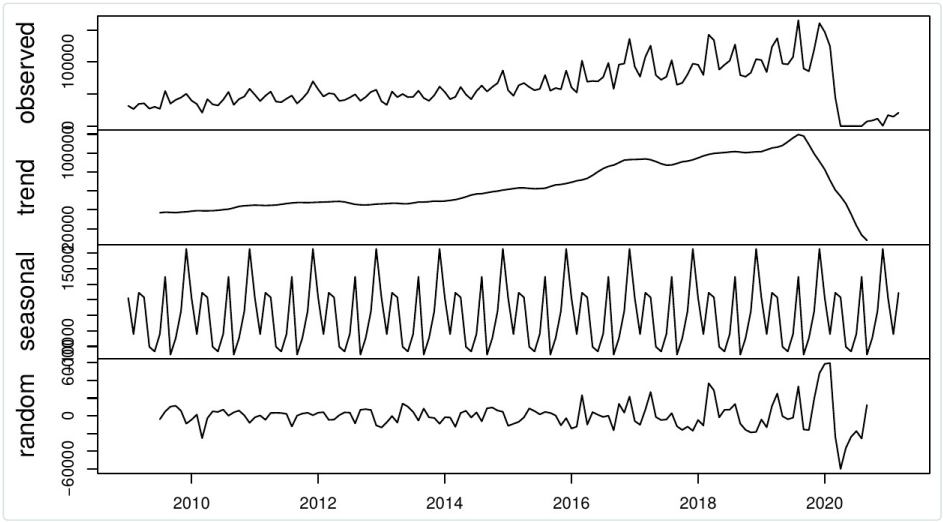
Modelo	MAE	RMSE	AIC	BIC
Prophet	97,589.88	107,976.80	-	-
ARIMA	102,566.16	121,487.80	2373.99	2391.89
Holt-Winters	150,681.72	169,332.70	-	-
ETS	193,116.55	210,431.50	3867.54	3912.40
Seasonal Naive	235,730.91	253,203.40	-	-

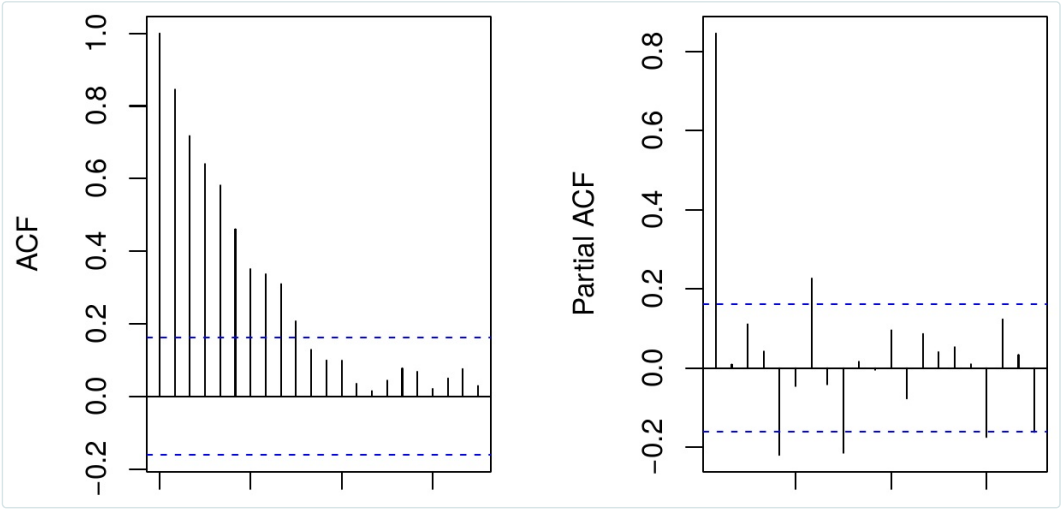
Ganador en predicción: Prophet. Prophet ganó por goleada (MAE 97,589 vs. 102,566 del ARIMA). Tiene sentido: es el que mejor se las arregla con el quiebre brusco de la pandemia.

El Salvador

Periodo de entrenamiento: ene-2009 a mar-2021 · mensual.

Crecimiento sostenido hasta 2020 y un patrón estacional bastante estable. La pandemia le pega fuerte, como a todas.





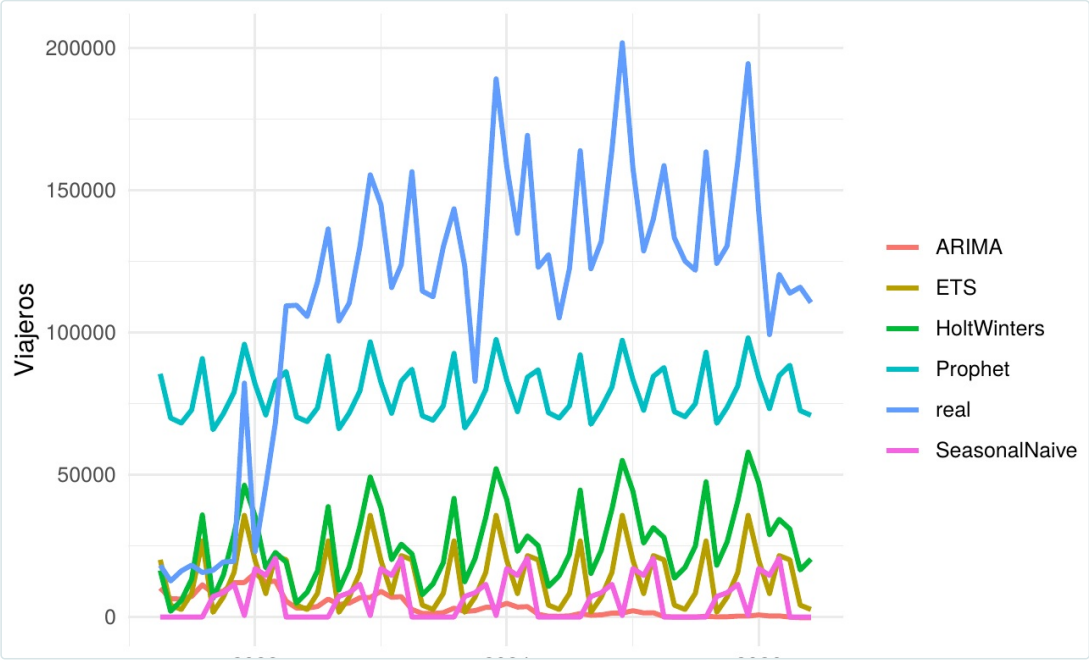
Box-Cox sugerido λ=0.521 (¿se transformó? Sí). ADF p=0.268, d=1, D=0. No estacionaria (ADF p=0.268), se resuelve con d=1. El modelo automático no necesitó términos AR/MA regulares, solo componente estacional — la dependencia acá es casi puramente estacional.

Candidatos ARIMA probados (ganador en negrita más abajo):

Candidato	AIC	BIC
auto	1755.69	1764.65
simple	1761.33	1773.26
ma_mayor	1763.31	1778.23

Nos quedamos con **ARIMA(0,1,0)(1,0,1)[12]** (AIC 1755.69, BIC 1764.64). Ljung-Box p=0.400 → sin problema de autocorrelación en los residuos.

El ETS automático fue ETS(A,N,A) (AIC 3612.87); también se corrieron Holt-Winters, Seasonal Naive y Prophet.



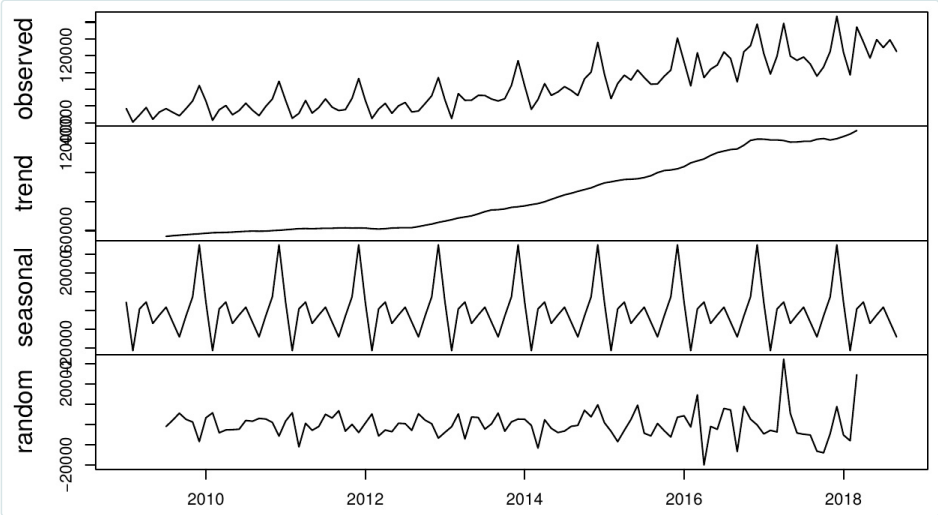
Modelo	MAE	RMSE	AIC	BIC
Prophet	53,252.87	56,540.06	-	-
Holt-Winters	89,071.47	97,111.37	-	-
ETS	100,181.96	109,351.08	3612.87	3657.73
Seasonal Naive	107,474.05	117,633.37	-	-
ARIMA	110,040.37	120,925.30	1755.69	1764.64

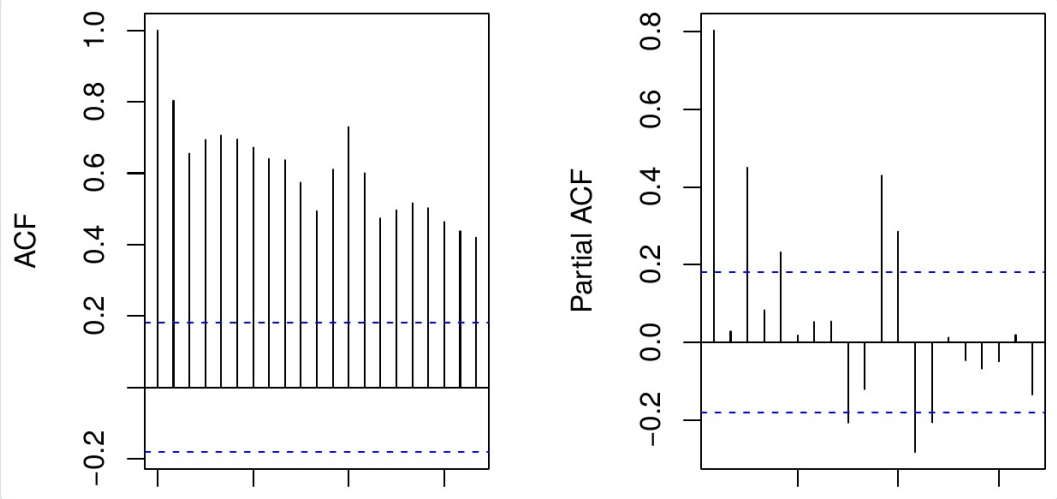
Ganador en predicción: Prophet. Otra vez Prophet al frente, y con bastante ventaja. Le sabe seguir el paso a la caída y a la recuperación.

Guatemala

Periodo de entrenamiento: ene-2009 a sep-2018 · mensual.

La serie con más historia acumulada, así que su corte de entrenamiento (70%) queda antes de la pandemia. Tendencia fuerte y la estacionalidad más marcada de todo el análisis.





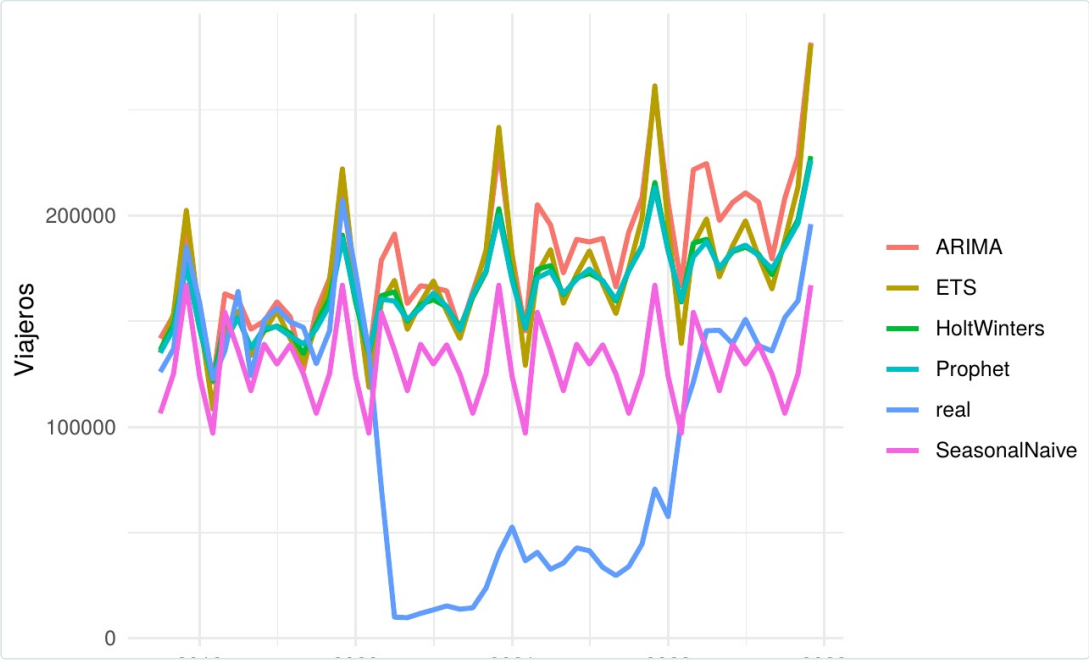
Box-Cox sugerido λ=0.279 (¿se transformó? Sí). ADF p=0.031, d=1, D=1. Ojo con esta: el ADF por sí solo daba p=0.031 (“estacionaria”), pero la tendencia y estacionalidad tan marcadas hicieron que ndiffs/nsdiffs recomendaran igual diferenciar en ambas partes (d=1, D=1). El ADF simple no capta bien la estacionalidad fuerte.

Candidatos ARIMA probados (ganador en negrita más abajo):

Candidato	AIC	BIC
auto	454.07	464.64
ar_mayor	460.20	476.07
simple	461.24	471.82
ma_mayor	461.39	474.61

Nos quedamos con **ARIMA(0,1,1)(2,1,0)[12]** (AIC 454.07, BIC 464.64). Ljung-Box p=0.507 → residuos ok.

El ETS automático fue ETS(M,A,M) (AIC 2631.19); también se corrieron Holt-Winters, Seasonal Naive y Prophet.



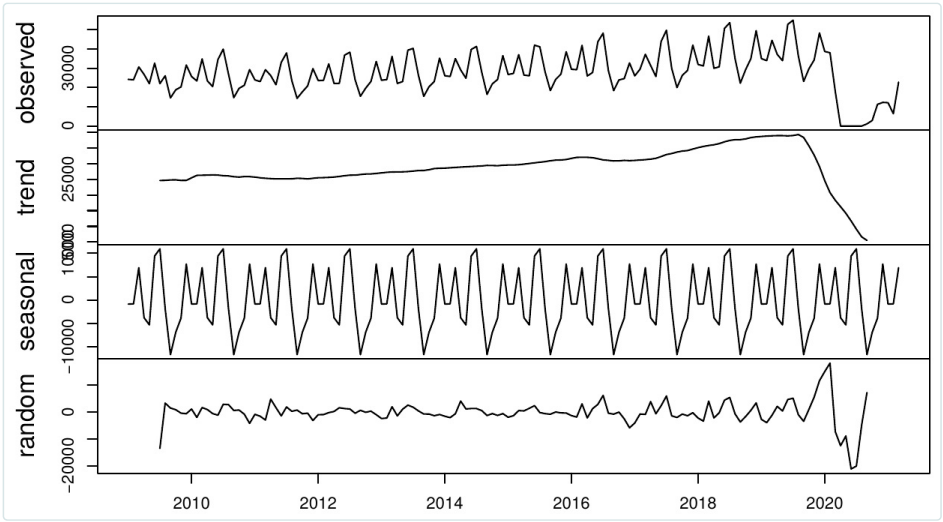
Modelo	MAE	RMSE	AIC	BIC
Seasonal Naive	56,259.91	69,513.09	-	-
Prophet	72,668.67	93,388.29	-	-
Holt-Winters	73,615.21	94,011.16	-	-
ETS	77,706.78	99,073.17	2631.19	2678.14
ARIMA	86,315.96	107,459.21	454.07	464.64

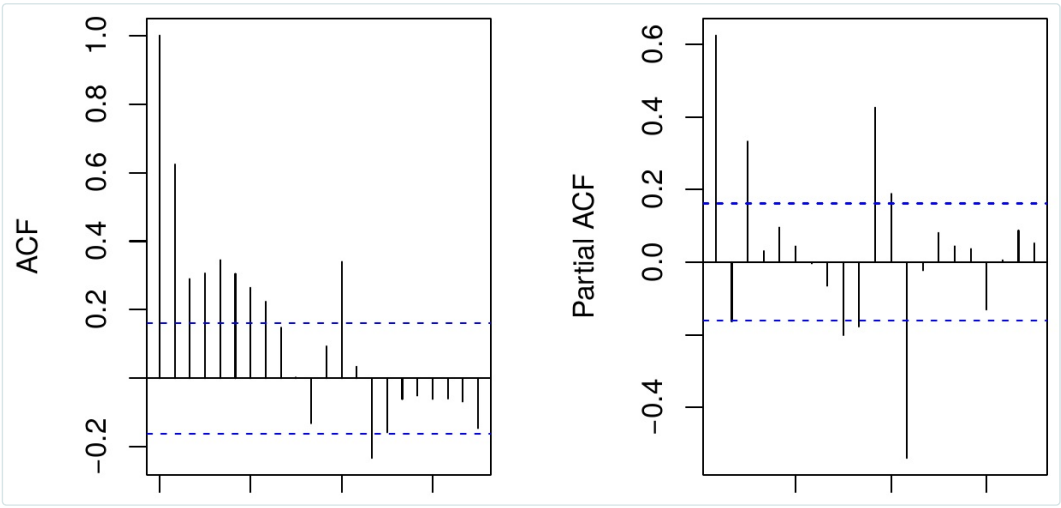
Ganador en predicción: Seasonal Naive. Acá gana el método más tonto de todos: repetir el mismo mes del año pasado. Y no es casualidad — es la serie con la estacionalidad más fuerte, así que ese “truco” barato funciona mejor que los modelos sofisticados.

Estados Unidos

Periodo de entrenamiento: ene-2009 a mar-2021 · mensual.

Crecimiento moderado y estacionalidad bien marcada hasta el frenazo de la pandemia.





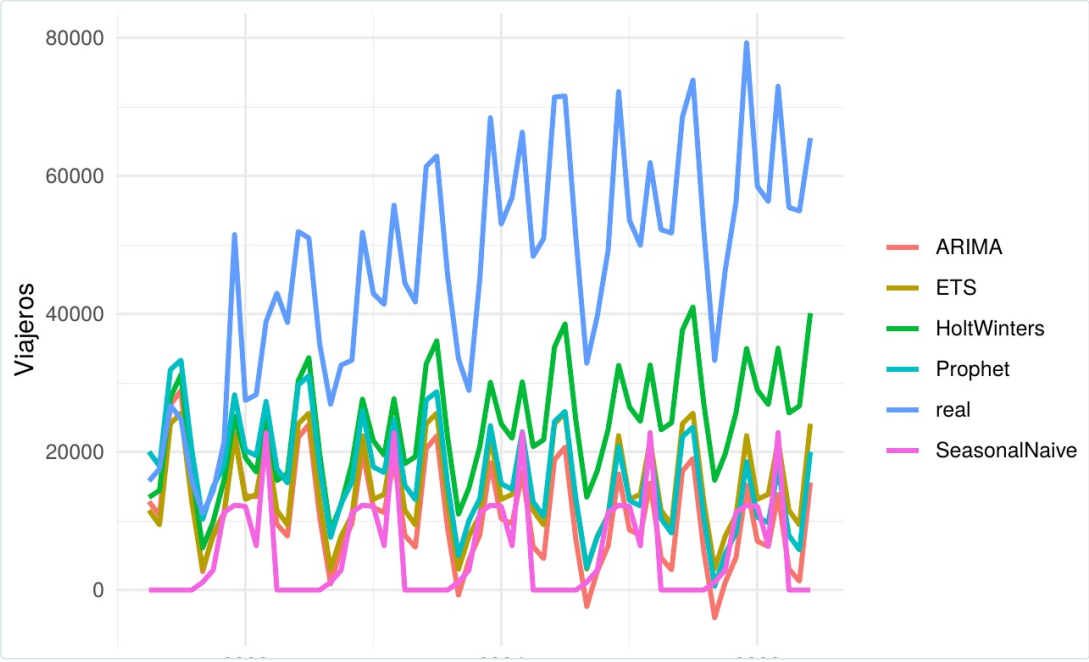
Box-Cox sugerido λ=0.856 (¿se transformó? No). ADF p=0.409, d=0, D=1. ADF (p=0.409) confirma no estacionariedad. El sugerido era D=1 en la parte estacional, y el auto.arima terminó metiendo también una diferenciación regular al ajustar — normal, porque hay tendencia y estacionalidad a la vez.

Candidatos ARIMA probados (ganador en negrita más abajo):

Candidato	AIC	BIC
auto	2685.05	2699.53
simple	2698.98	2710.60
ma_mayor	2700.97	2715.50
ar_mayor	2702.75	2720.18

Nos quedamos con **ARIMA(1,1,1)(0,1,2)[12]** (AIC 2685.05, BIC 2699.53). Ljung-Box p=0.965 → residuos muy limpios, el mejor ajuste ARIMA de todo el laboratorio.

El ETS automático fue ETS(A,N,A) (AIC 3239.94); también se corrieron Holt-Winters, Seasonal Naive y Prophet.



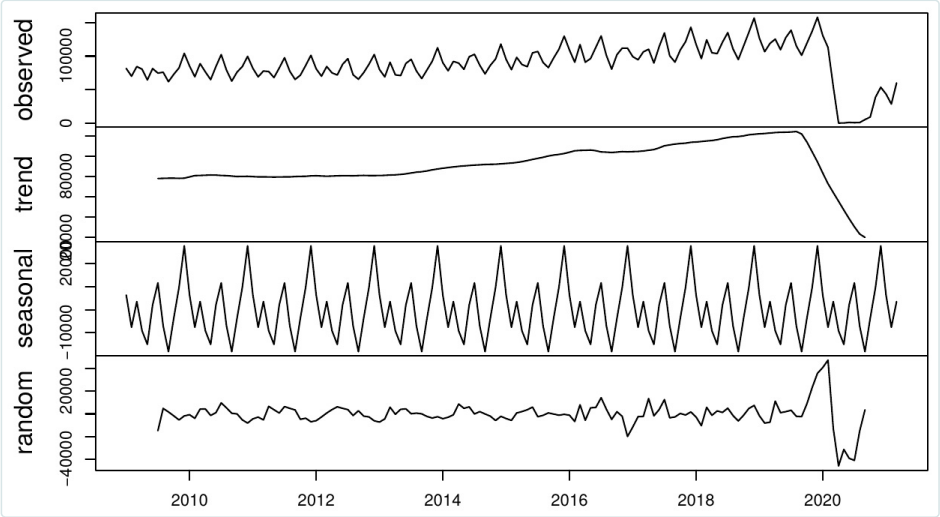
Modelo	MAE	RMSE	AIC	BIC
Holt-Winters	23,097.58	25,168.66	-	-
Prophet	30,643.78	34,279.44	-	-
ETS	31,964.28	34,667.75	3239.94	3284.80
ARIMA	35,691.95	39,012.48	2685.05	2699.53
Seasonal Naive	41,167.83	44,196.20	-	-

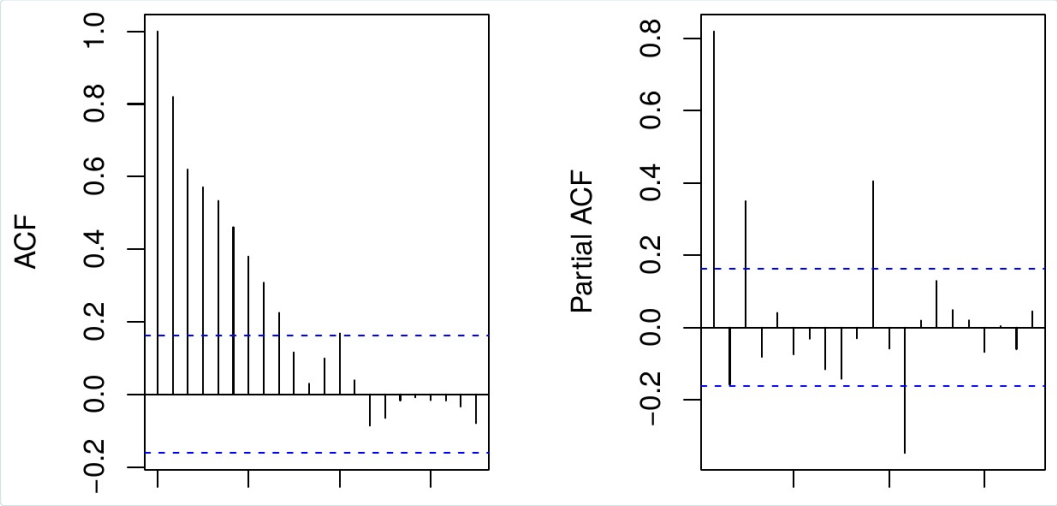
Ganador en predicción: Holt-Winters. Holt-Winters se lleva el premio acá: tendencia y estacionalidad estables, justo lo que este método sabe modelar bien.

Vía Aérea

Periodo de entrenamiento: ene-2009 a mar-2021 · mensual.

Crece sostenido, estacionalidad marcada (temporadas altas/bajas típicas de vuelos) y caída fuerte en 2020.





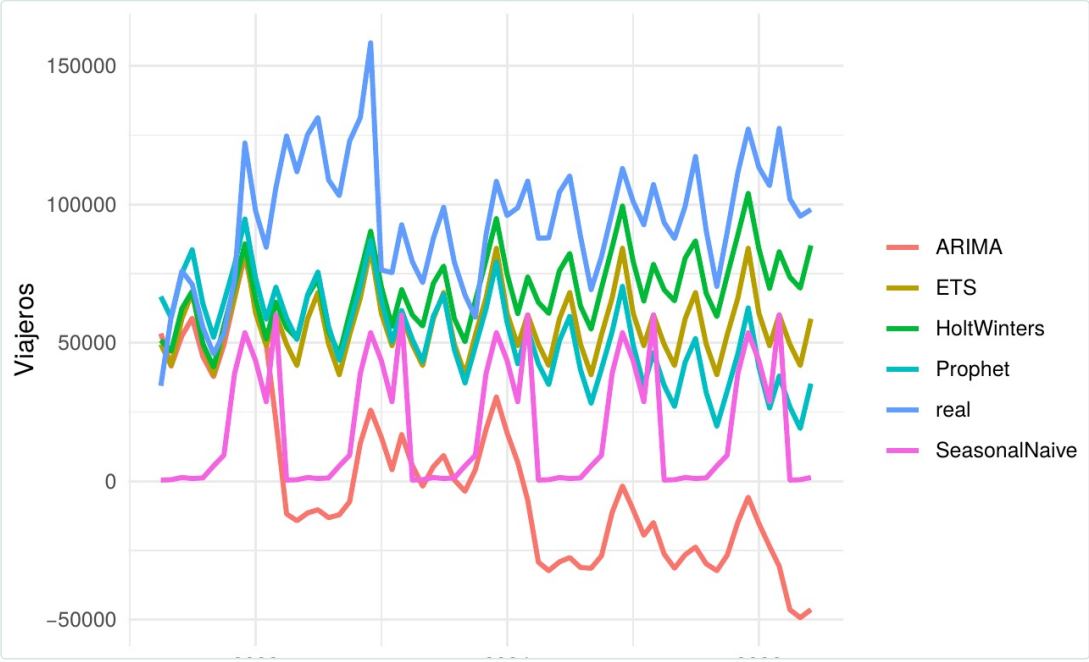
Box-Cox sugerido λ=1.109 (¿se transformó? No). ADF p=0.423, d=1, D=0. No estacionaria (ADF p=0.423), se arregla con d=1; no hizo falta diferenciar la parte estacional.

Candidatos ARIMA probados (ganador en negrita más abajo):

Candidato	AIC	BIC
auto	3171.26	3186.17
simple	3226.50	3238.43
ma_mayor	3227.22	3242.14

Nos quedamos con **ARIMA(0,1,2)(2,0,0)[12]** (AIC 3171.26, BIC 3186.17). Ljung-Box p=0.725 → sin drama en los residuos.

El ETS automático fue ETS(A,N,A) (AIC 3468.17); también se corrieron Holt-Winters, Seasonal Naive y Prophet.



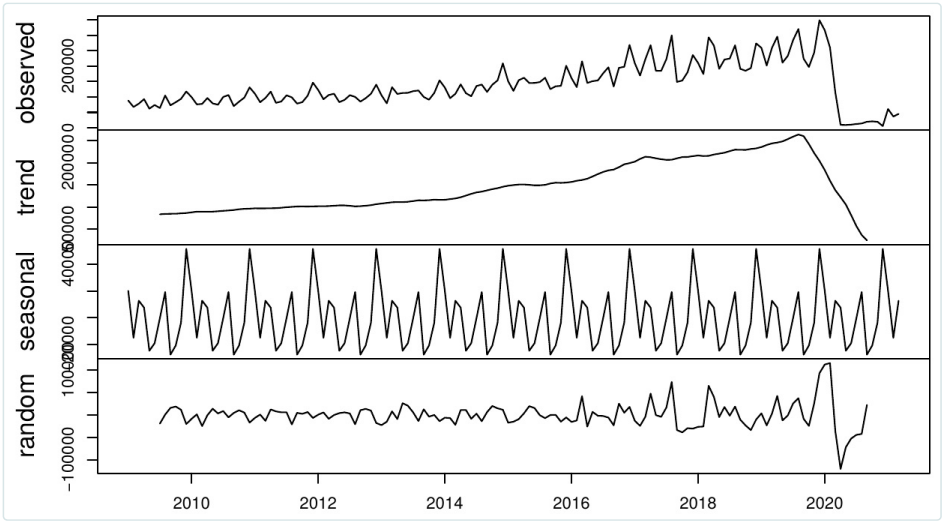
Modelo	MAE	RMSE	AIC	BIC
Holt-Winters	26,342.67	31,317.38	-	-
ETS	38,735.12	42,766.44	3468.17	3513.03
Prophet	44,233.01	49,111.16	-	-
Seasonal Naive	75,103.70	79,077.33	-	-
ARIMA	95,002.91	103,951.09	3171.26	3186.17

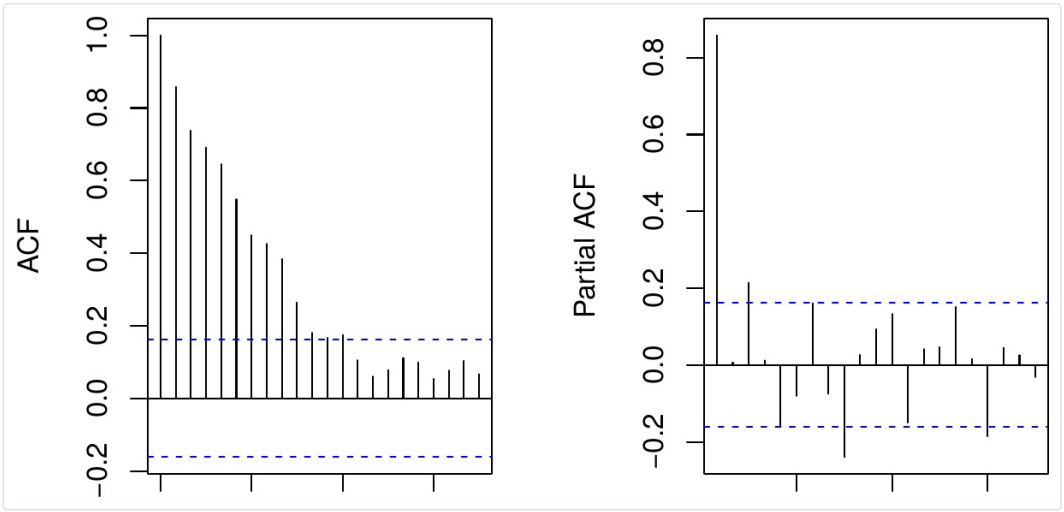
Ganador en predicción: Holt-Winters. De nuevo Holt-Winters arriba: tendencia + estacionalidad juntas, su especialidad.

Vía Terrestre

Periodo de entrenamiento: ene-2009 a mar-2021 · mensual.

Crecimiento gradual, caída fuerte en pandemia y recuperación parcial después.





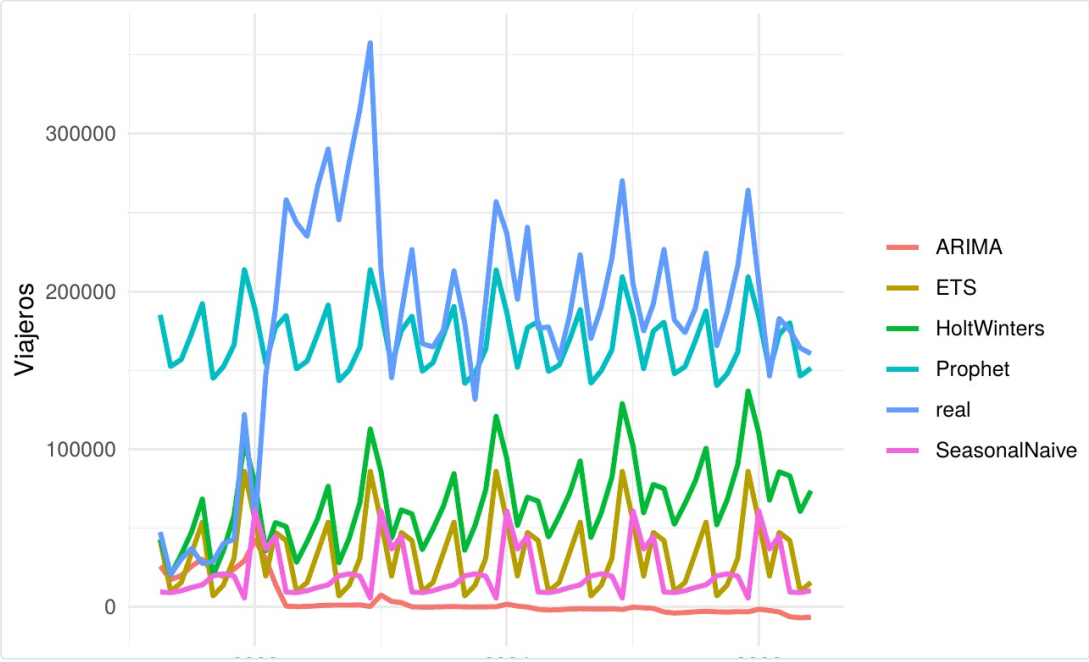
Box-Cox sugerido λ=0.487 (¿se transformó? Sí). ADF p=0.509, d=1, D=0. No estacionaria (ADF p=0.509), se corrige con d=1. Tras diferenciar, la dependencia que queda es básicamente estacional (solo términos SAR).

Candidatos ARIMA probados (ganador en negrita más abajo):

Candidato	AIC	BIC
auto	1701.35	1710.30
ar_mayor	1704.62	1722.52
simple	1717.63	1729.56
ma_mayor	1720.22	1735.14

Nos quedamos con **ARIMA(0,1,0)(2,0,0)[12]** (AIC 1701.35, BIC 1710.30). Ljung-Box p=0.269 → residuos ok.

El ETS automático fue ETS(A,N,A) (AIC 3801.96); también se corrieron Holt-Winters, Seasonal Naive y Prophet.



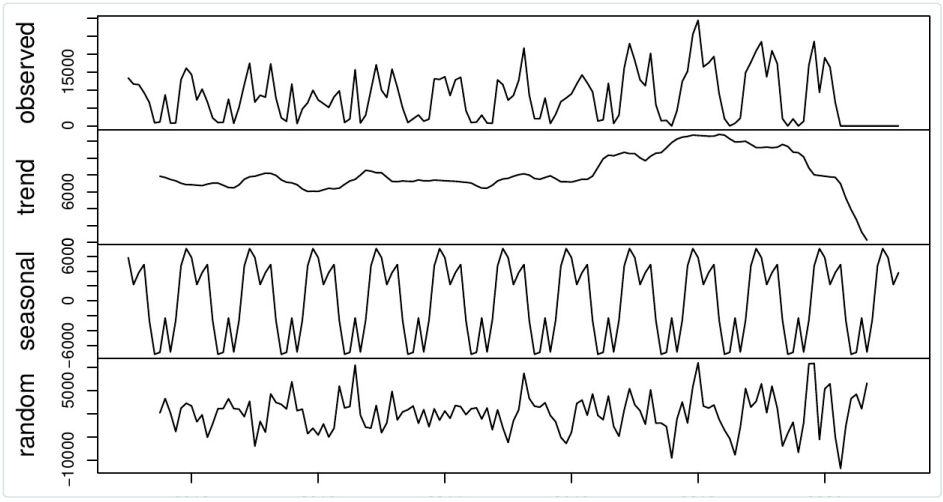
Modelo	MAE	RMSE	AIC	BIC
Prophet	54,308.76	71,306.26	-	-
Holt-Winters	117,916.99	132,395.38	-	-
ETS	148,052.81	162,627.68	3801.96	3846.82
Seasonal Naive	160,013.01	176,652.99	-	-
ARIMA	177,178.38	194,800.94	1701.35	1710.30

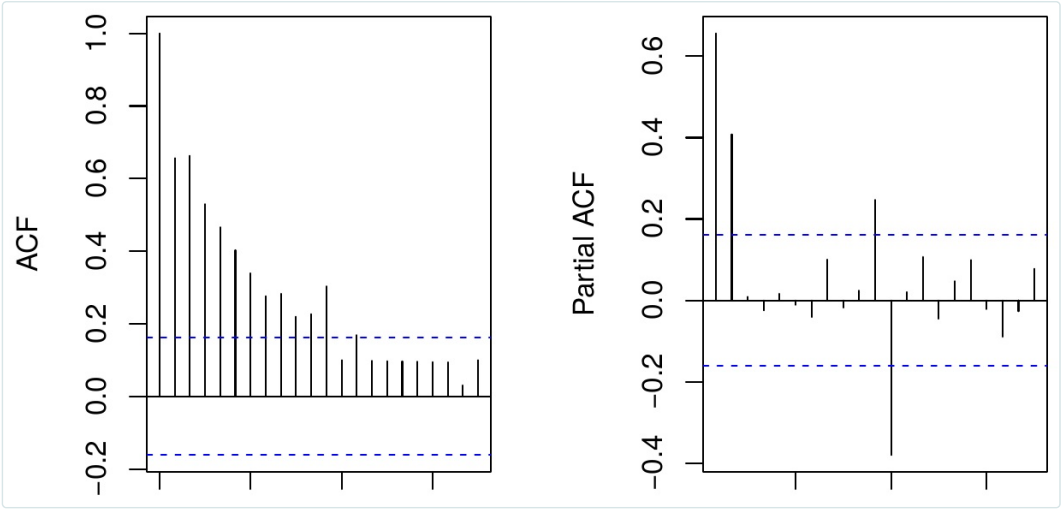
Ganador en predicción: Prophet. Prophet vuelve a ganar con margen amplio, gracias a que absorbe mejor el bajón y la recuperación pospandemia.

Vía Marítima

Periodo de entrenamiento: ene-2009 a mar-2021 · mensual.

La más inestable de todas: mucha variabilidad, caída fuerte en pandemia y recuperación bastante irregular.





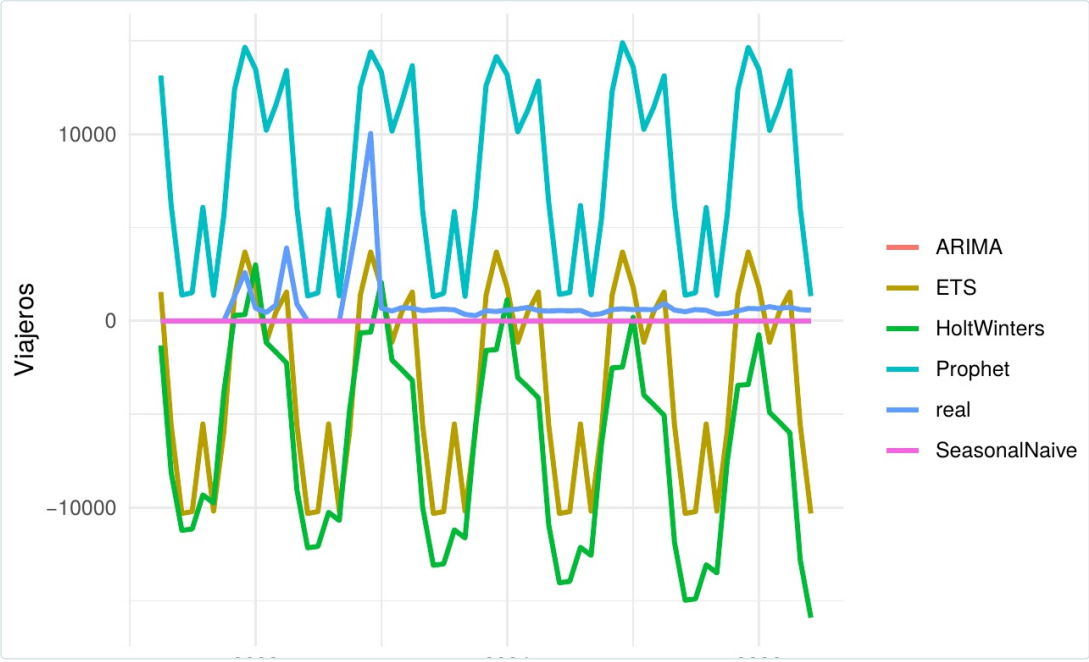
Box-Cox sugerido λ=0 (log) (¿se transformó? Sí). ADF p=0.640, d=1, D=0. No estacionaria (ADF p=0.640), se corrige con d=1.

Candidatos ARIMA probados (ganador en negrita más abajo):

Candidato	AIC	BIC
auto	2831.74	2849.64
ar_mayor	2836.26	2854.16
simple	2840.07	2852.01
ma_mayor	2841.08	2856.00

Nos quedamos con **ARIMA(0,1,3)(0,0,2)[12]** (AIC 2831.74, BIC 2849.64). Ljung-Box p=0.0000032 → **acá sí hay problema**: quedan residuos autocorrelacionados. El modelo no logra capturar del todo la dinámica de esta serie tan volátil (es la de mayor CV, 0.868).

El ETS automático fue ETS(A,N,A) (AIC 3227.09); también se corrieron Holt-Winters, Seasonal Naive y Prophet.



Modelo	MAE	RMSE	AIC	BIC
ARIMA	858.37	1,731.93	2831.74	2849.64
Seasonal Naive	858.37	1,731.93	-	-
ETS	5,010.37	6,354.68	3227.09	3271.95
Prophet	7,209.45	8,534.39	-	-
Holt-Winters	7,605.85	8,920.36	-	-

Ganador en predicción: ARIMA (empatado con Seasonal Naive). ARIMA y Seasonal Naive quedan prácticamente clavados en el mismo error. O sea que, pese a lo volátil que es esta serie, en el corto plazo su estructura es bastante simple — aunque la autocorrelación que queda en los residuos nos dice que no hay que confiar demasiado en ella para el largo plazo.

5. Ahora sí, lo interesante: comparando resultados

¿Qué modelo ganó en cada serie, y por qué?

Serie	Mejor modelo	MAE	RMSE	Pista de por qué gana
General	Prophet	97,589.88	107,976.80	Absorbe mejor el quiebre de la pandemia que un ARIMA/ETS “rígido”.
El Salvador	Prophet	53,252.87	56,540.06	Mismo motivo: sigue la caída y la recuperación sin perder el ritmo.
Guatemala	Seasonal Naive	56,259.91	69,513.09	Es la serie con la estacionalidad más fuerte de todas (0.793) — repetir el mes del año pasado le gana a modelos mucho más sofisticados.
Estados Unidos	Holt-Winters	23,097.58	25,168.66	Tendencia y estacionalidad estables, justo lo que Holt-Winters modela de forma explícita.
Vía Aérea	Holt-Winters	26,342.67	31,317.38	Misma historia que Estados Unidos.
Vía Terrestre	Prophet	54,308.76	71,306.26	De nuevo, mejor manejo del bache pandémico y su recuperación.
Vía Marítima	ARIMA / Seasonal Naive (empate)	858.37	1,731.93	Serie muy volátil pero con estructura de corto plazo simple; aun así, sus residuos ARIMA quedan con autocorrelación (Ljung-Box p≈0), así que no confiaríamos en ella para el largo plazo.

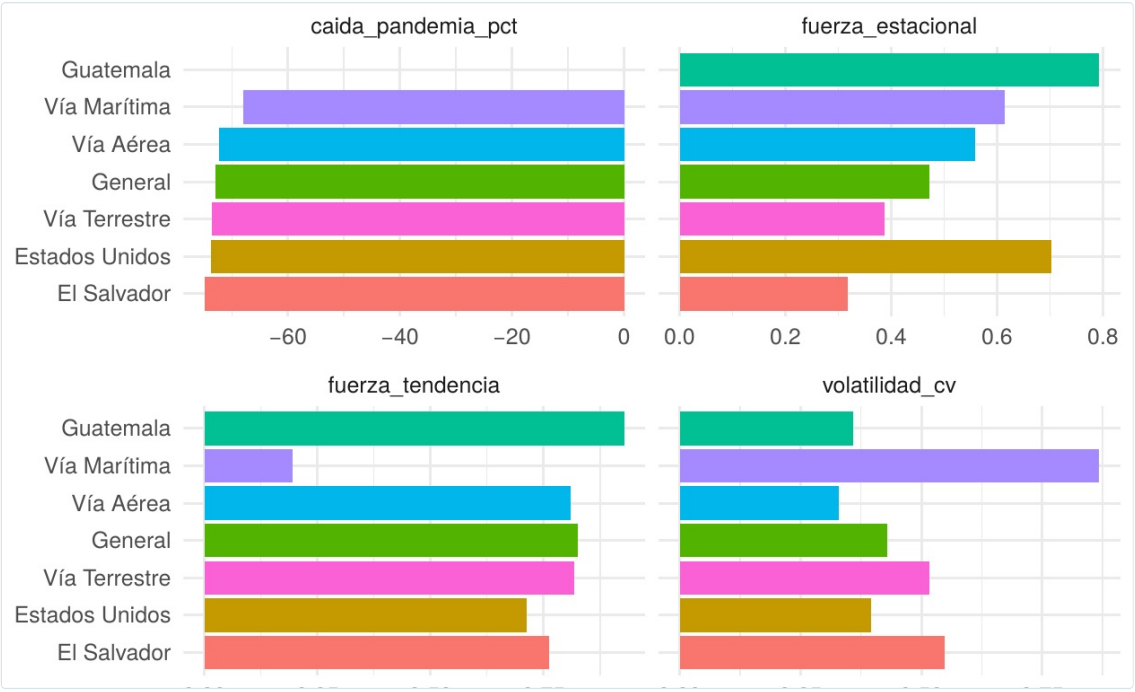
Patrón que se repite: cuando hay un quiebre estructural fuerte (pandemia) y el resto del comportamiento es más o menos regular, **Prophet gana**. Cuando la serie es estable y sin sobresaltos raros, **Holt-Winters gana** porque modela tendencia + estacionalidad de forma directa. Y cuando la estacionalidad es tan brutal que domina todo, ni hace falta un modelo sofisticado: **Seasonal Naive** (el “cópiame el año pasado”) le gana a todos. Moraleja: no existe un modelo único que sirva para todo el portafolio – conviene elegir según el “carácter” de cada serie.

Estacionalidad, tendencia, volatilidad e impacto de la pandemia

Para no quedarnos solo con la intuición visual, calculamos cuatro indicadores por serie: fuerza estacional y fuerza de tendencia (comparando varianzas en la descomposición), volatilidad (coeficiente de variación) y la caída porcentual 2019→2020.

Serie	Fuerza estacional	Fuerza de tendencia	Volatilidad (CV)	Caída pandemia (%)
Guatemala	0.793	0.928	0.359	N/D*
Estados Unidos	0.703	0.712	0.396	-73.7
Vía Marítima	0.614	0.196	0.868	-67.9
Vía Aérea	0.558	0.809	0.330	-72.3
General	0.472	0.826	0.430	-73.0
Vía Terrestre	0.387	0.818	0.517	-73.6
El Salvador	0.318	0.763	0.548	-74.9

* El entrenamiento de Guatemala corta en sep-2018, antes de la pandemia, así que no se puede calcular esa caída con este método.



Sacando cuentas:

- **La más estacional: Guatemala** (0.793) — el patrón de “todos los años se repite igual” es clarísimo acá.
- **La de tendencia más fuerte: también Guatemala** (0.928) — crece sostenido, sin dudarlo.
- **La más volátil, lejos: Vía Marítima** (CV 0.868) — casi el doble que la siguiente más volátil. Es la que más sorpresas da.
- **La más golpeada por la pandemia (entre las comparables): El Salvador** (-74.9%), pegadita a Estados Unidos, General, Vía Aérea y Vía Terrestre (todas entre -72% y -74%). La **Vía Marítima fue la que menos cayó relativamente** (-67.9%) — raro para ser la más volátil, pero probablemente porque partía de una base ya chica y volvió a operar rápido (cruceros).

Entonces, ¿qué le sirve a INGUAT?

1. **Guatemala es la serie más predecible en el sentido “de calendario”**: tendencia fuerte + estacionalidad fuerte = se puede planificar personal e infraestructura con bastante anticipación, mes a mes.
2. **La vía marítima necesita ojo constante, no un modelo fijo**: con ese nivel de volatilidad, cualquier modelo que se deje de actualizar se queda obsoleto rápido. Conviene reentrenar seguido y no fiarse de una sola proyección a largo plazo.
3. **La pandemia no fue pareja**: todas las series cayeron fuerte (70-75%), pero la vía marítima aguantó relativamente mejor. Si vuelve a pasar algo similar, esa vía podría ser la que se recupere primero.
4. **General, Vía Aérea y Guatemala** son las que muestran la recuperación pospandemia más sólida (fuerza de tendencia 0.8-0.9) — son buenas candidatas para proyecciones de mediano plazo con más confianza.
5. **No conviene usar un solo modelo para todo INGUAT.** Como vimos, el mejor modelo cambia según si la serie tuvo un quiebre fuerte (ahí gana Prophet), si es estable (gana Holt-Winters) o si es muy estacional (gana el naive). Lo más sano es mantener un modelo por segmento y revisar cuál sigue siendo el mejor cada cierto tiempo, sobre todo después de choques como una pandemia.
6. **Como no hay datos faltantes ni duplicados**, y la demanda está bien concentrada en pocos países (El Salvador, Guatemala, EE.UU.), pocas regiones (Centro y Norteamérica) y pocas fronteras (La Aurora, Valle Nuevo, San Cristóbal), se puede enfocar el monitoreo y la promoción turística en esos puntos de alto volumen sin descuidar la vía marítima por su comportamiento errático.